








Web Scrapping

Coletando, estruturando e exportando dados da web com Python

Start


Henrique Augusto





O que é Web Scrapping?

- Automatizar a coleta e extração de dados de sites da web.
- Como copiar e colar dados de 100 páginas manualmente?
- Um robô (script) faz a requisição, "lê" a estrutura da página e extrai exatamente o dado desejado em segundos.



Para que serve?

- Inteligência de Mercado
- Pesquisa Acadêmica & Jornalismo de Dados
- Agregadores de Serviços
- Treinamento de IA





VS

Scraper



- Foco: Extração, filtragem e estruturação de dados específicos.
- Mecanismo: Acessa uma URL predefinida, inspeciona a estrutura do código (HTML/JSON) e captura apenas os campos desejados.
- Propósito: Transformar dados brutos não estruturados da tela em planilhas ou bancos de dados utilizáveis.
- Exemplo Prático: Coletar título, visualizações e comentários de vídeos específicos do YouTube para análise de dados.

Crawler



- Foco: Navegação, descoberta e mapeamento da web.
- Mecanismo: Parte de uma lista de URLs iniciais (seeds) e segue recursivamente os hiperlinks de cada página encontrada.
- Propósito: Descobrir a estrutura dos sites e criar índices para navegação rápida.
- Exemplo Prático: O Googlebot varrendo a internet continuamente para manter as buscas do Google atualizadas.






Questões Legais e Ética em Scraping

- Dados Públicos vs. Dados Privados: Raspar o que é público é permitido; burlar logins/autenticações sem autorização violará termos de uso.
- Legislação (LGPD): Atenção redobrada na coleta de dados pessoais e sensíveis de pessoas físicas.
- Arquivo robots.txt: O manual de "boas maneiras" que todo site publica indicando o que pode ser raspado.
- Impacto no Servidor: Fazer requisições demais por segundo pode ser interpretado como um ataque (DDoS). Respeite pausas (delays)!





Formas de Automatizar a Coleta Diária



- **Agendadores (Crontab / Windows Task Scheduler):** seu próprio computador.
- **Nuvem (AWS Lambda, GCP Cloud Functions):** sem necessidade de manter um servidor próprio ligado 24h.
- **Workflow (Airflow, GitHub Actions):** agendamento diário automático rodando e salvando arquivos diretamente no repositório ou nuvem.





Ecossistema de Bibliotecas Python


- **Requests / urllib:** Envia requisições HTTP e baixa o código bruto (HTML/JSON).
- **BeautifulSoup:** Faz o parsing (leitura) e busca tags em páginas HTML estáticas.
- **Selenium / Playwright:** Controla um navegador real. Usado quando a página depende muito de interações com JavaScript (cliques, scroll infinito).
- **Scrapy:** Framework robusto e de alta performance para grandes projetos de scraping.
- **Pandas:** Manipula, limpa e exporta os dados extraídos em CSV, Excel, Parquet, etc.





Por que um scraper para YouTube?


- Garantia de Estabilidade
- Uso da API Oficial
- Volume de Dados
- Foco Didático
- Detalhe cada scraper é único! :)





Principais Libs do Projeto




- **google-api-python-client:** Biblioteca oficial do Google para conectar e fazer requisições na YouTube Data API v3.
- **pandas:** Organização dos dados em DataFrames e exportação limpa para arquivos .csv.
- **python-dotenv:** Gerenciamento seguro de credenciais e chaves de acesso no ambiente local.






Segurança do Código: .env e .gitignore

- Não podemos subir credenciais e chaves de API para o GitHub de forma pública.
- A Solução com **python-dotenv**:
 - Guardar senhas e chaves no .env.
 - Carregar no Python via `os.getenv("YOUTUBE_API_KEY")`.
- **gitignore**: Arquivo que instrui o Git a nunca subir o .env para o repositório remoto.




a Chave de API do YouTube?

- Credencial alfanumérica única
- Autenticação e Permissão
- Controle de Cotas
- Segurança e Monitoramento



Tutorial Chave de API do YouTube



The screenshot shows the Google Cloud console dashboard. At the top, there's a navigation bar with the Google Cloud logo, a search bar, and a user profile icon. The main content area features a large 'Olá!' greeting with a red arrow pointing to the 'Criar chave da API Gemini' button. Below this, there are several quick-start buttons for various services like BigQuery, IAM, and Compute Engine. A 'Teste o chat do Gemini Cloud Assist' dialog box is also visible on the right side.

Google Cloud Seleccione um projeto Pesquise (/) recursos, documentos, produtos e muito mais Pesquisa

Olá!

Crie ou selecione um projeto para começar a usar o Google Cloud. [Saiba mais sobre projetos](#)

[Painel](#) [Cloud Hub](#)

[+ Criar chave da API Gemini](#) [+ Criar um agente](#) [+ Criar uma VM](#)

[+ Executar uma consulta no BigQuery](#) [+ Implantar um aplicativo](#) [+ Criar um bucket de armazenamento](#)

Teste o chat do Gemini Cloud Assist

Inicie um chat agora →


Acesso rápido

API APIs e serviços IAM e admin Faturamento Compute Engine

Cloud Storage BigQuery Rede VPC Kubernetes Engine

[Ver todos os produtos](#)

Tutorial Chave de API do YouTube



Tutorial Chave de API do YouTube

Novo projeto



Voce tem 12 projects restantes na sua cota. Solicite um aumento ou exclua projetos. [Saiba mais](#)

[Manage Quotas](#)

Nome do projeto *

Minicurso-YouTube-Scraper



ID do projeto: minicurso-youtube-scraper. Não é possível mudar depois. [Editar](#)

Recurso pai *

 Nenhuma organização

[Procurar](#)

Selecione a organização ou pasta em que esse recurso será criado

[Criar](#)

[Cancelar](#)


Tutorial Chave de API do YouTube

The image shows the Google Cloud console interface for the project "Minicurso-YouTube-Scraper". The left sidebar contains navigation links for Cloud Hub, Visão geral do Cloud, Soluções, and Acessados recentemente. Below these are "Produtos preferidos" and a list of products including Faturamento, IAM e admin, Marketplace, APIs e serviços, Plataforma do agente, Compute Engine, Kubernetes Engine, Cloud Storage, Segurança, BigQuery, and Monitoramento. A button "Mostrar todos os produtos" is at the bottom of the sidebar.


The main content area displays the "YouTube Data API v3" search results. The search bar at the top right contains "Pesquisa". The results are organized into sections: "Principais resultados", "Produtos e páginas", "Documentação e tutoriais", and "Marketplace". The "Principais resultados" section lists the API, endpoints, and error reporting. The "Produtos e páginas" section lists endpoints and error reporting. The "Documentação e tutoriais" section lists documentation links. The "Marketplace" section lists the API. A red arrow points to the "Go to Cloud Hub" button in the background.

A blue notification box at the bottom of the screen displays the message: "Exibindo o projeto 'Minicurso-YouTube-Scraper' na organização 'Nenhuma organização'".

Tutorial Chave de API do YouTube



Tutorial Chave de API do YouTube



The screenshot shows the Google Cloud console interface. The top bar includes the Google Cloud logo, the project name 'Minicurso-YouTube-Scraper', and the selected API 'YouTube Data API v3'. The left sidebar lists various API-related options, with 'Credenciais' (Credentials) highlighted by a red arrow. The main content area displays the details for the 'YouTube Data API v3', including a description and a table of service details.

Google Cloud Minicurso-YouTube-Scraper YouTube Data API v3

APIs e serviços

- APIs e serviços ativados
- Biblioteca
- Credenciais
- Tela de permissão OAuth
- Contratos de uso de pá...


Detalhes de API/serviço Desabilitar API

Para chamar essa API dos seus aplicativos, talvez seja necessário criar credenciais.


YouTube Data API v3
The YouTube Data API v3 is an API that provides access to YouTube data, such as videos, playlists, and channels.
Por Google

Nome de serviço	Tipo	Status
youtube.googleapis.com	API pública	Ativadas

Tutorial Chave de API do YouTube



Tutorial Chave de API do YouTube



Tutorial Chave de API do YouTube

Nome *

Minicurso

Use um nome exclusivo para identificar sua chave de API

APIs que podem ser acessadas usando esta chave

Criação de novas chaves: para usar as APIs Agent Platform (Vertex) ou Gemini, a chave de API precisa ser vinculada a uma conta de serviço. Um seletor de conta de serviço vai aparecer automaticamente quando você selecionar essas APIs.

Observação: uma [política da organização](#) rege a criação de chaves de API vinculadas a uma conta de serviço para projetos de uma organização do Google Cloud. [Saiba mais](#)

Selecionar restrições da API *

Filtrar

Digite para filtrar

Cloud Trace API

Dataform API

Google Cloud APIs

Google Cloud Storage JSON API

Service Management API

Service Usage API

Telemetry API

YouTube Data API v3

Cancelar

OK

APIs selecionadas:

YouTube Data API v3

☐

Autenticar chamadas de API por uma conta de serviço

As chamadas de API feitas por essa chave serão autenticadas pela conta de serviço vinculada. Essa opção é necessária para acessar algumas APIs, como a API Agent Platform ou a API Gemini.

Restrinja sua chave para reduzir os riscos de segurança

Selecione um tipo de aplicativo específico para restringir o acesso

Restrições do aplicativo

☒

Nenhum

☐

Sites

☐

Endereços IP

☐

Apps Android

☐


Apps iOS

Tutorial Chave de API do YouTube

Chaves de API

☐	☒	Nome	Bound account [?]	Data da criação ↓	Restrições	Ações
☐	☒	Minicurso	—	27 de ago. de 2026	YouTube Data API v3 ...	Exibir chave ⋮





Mãos à obra!

Ok